

# Metoda odwrotnej dystrybucji.

Piotr Fonferek

12 stycznia 2024

# Rozkład jednostajny

Założmy, że istnieje ciąg niezależnych zmiennych losowych  $U_1, U_2, \dots$ , takich że:

$$P(U_i \leq u) = \begin{cases} 0, & u < 0 \\ u, & 0 \leq u \leq 1 \\ 1, & u > 1 \end{cases}$$

Czyli te zmienne mają rozkład  $U[0, 1]$ .

# Metoda odwrotnej dystrybucyjności

## Twierdzenie


Założmy, że mamy rozkład  $\Phi$ , jego dystrybucję  $F$  i zmienną losową  $U$  o rozkładzie  $U[0, 1]$ . Wtedy dla zmiennej losowej

$$X := F^{-1}(U)$$

zachodzi  $P(X \leq x) = F(x)$  dla każdego  $x$ .



Czyli możemy uzyskać próbkę o dowolnym rozkładzie, znając tylko wzór na jego odwróconą dystrybucję i mając generator liczb losowych  $U[0, 1]$ .

# Metoda odwrotnej dystrybucyjności



# Metoda odwrotnej dystrybucyj

- 1 Jeśli w dystrybucyjce  $F$  występują skoki, to  $u_1 = F(x-) \leq u \leq u_2 = F(x+)$  są odwzorowane przez  $F^{-1}$  na  $x_0$ ;
- 2 Jeśli w dystrybucyjce  $F$  występują spłaszczenia, to przyjmujemy  $F^{-1}(u) = \inf\{x : F(x) \geq u\}$ .



# Metoda odwrotnej dystrybucyjności

Sprawdzenie, że ta metoda rzeczywiście zwraca próbkę o rozkładzie  $\Phi$ .

$$\begin{aligned}P(X \leq x) &= P(F^{-1}(U) \leq x) \\&= P(U \leq F(x)) \\&= F(x).\end{aligned}$$

# Percentyle

## Definicja

Percentyle są podziałem liczb rzeczywistych na rozłączne zbiory  $A_1, \dots, A_{100}$ , takie że  $\bigcup_{i=1}^{100} A_i = \mathbb{R}$ , dla których zachodzi

$$\Phi(A_k) = \Phi(A_i) \quad (1)$$

dla dowolnych  $k, i \in \{1, \dots, 100\}$ .

## Uwaga

Równość (1) zachodzi również, jeśli zbiory  $A_k$  i  $A_i$  składają się z sumy  $n$  różnych zbiorów  $A_1, \dots, A_{100}$ .

# Percentyle

## Przykład

Uzyskanie wyniku losowania z rozkładu  $\Phi$  pomiędzy dwudziestym a trzydziestym percentylem jest równie prawdopodobne, jak uzyskanie wyniku pomiędzy osiemdziesiątym, a dziewięćdziesiątym percentylem.

- Metoda odwrotnej dystrybucyjności pozwala na szybkie znalezienie percentyli.
- Ze wzoru (1) wynika, że percentyle mają rozkład jednostajny.



# Przykład - rozkład wykładniczy

Dystrybuanta  $F$  rozkładu wykładniczego o średniej  $\theta$  wynosi

$$F(x) = 1 - e^{-x/\theta}, \quad x \geq 0.$$

Teraz obliczamy  $F^{-1}$ :

$$U = 1 - e^{-\frac{x}{\theta}}$$

$$e^{-\frac{x}{\theta}} = 1 - U$$


$$X = -\theta \ln(1 - U) = -\theta \ln(U)$$

# Przykład - rozkład wykładniczy

```
1 #Metoda odwrotnej dystrybucyjności dla rozkładu wykładniczego
2 x = seq(from=0.01, to=20, by=0.01)
3 theta <- 0.5 #Średnia
4 lambda <- 1/theta
5 probka_wykladniczego <- c()
6 probka_wykladniczego <- -theta*log(runif(100))
7 hist(probka_wykladniczego, breaks = seq(0, 20, 0.5),
8      main="Histogram próbki rozkładu wykładniczego", prob=TRUE)
9 lines(x, lambda*exp(-lambda*x), col="red", lwd=2)
```

## Przykład - rozkład wykładniczy

Histogram próbki rozkładu wykładniczego



# Rozkład arcus sinusa

## Rozkład arcus sinusa

Rozkład o dystrybucji  $F(x) = \frac{2}{\pi} \arcsin(\sqrt{x})$ ,  $0 \leq x \leq 1$  jest nazywany rozkładem arcus sinusa.

Jego gęstość wynosi  $f(x) = \frac{1}{\pi \sqrt{x(1-x)}}$ .

## Prawa arcus sinusa

Niech zmienna losowa  $M$  określa czas, w którym proces Wienera osiągnął maksimum w czasie  $[0, 1]$ :

$$W_M = \sup\{W_s : s \in [0, 1]\}.$$

Wtedy  $M$  ma rozkład arcus sinusa.

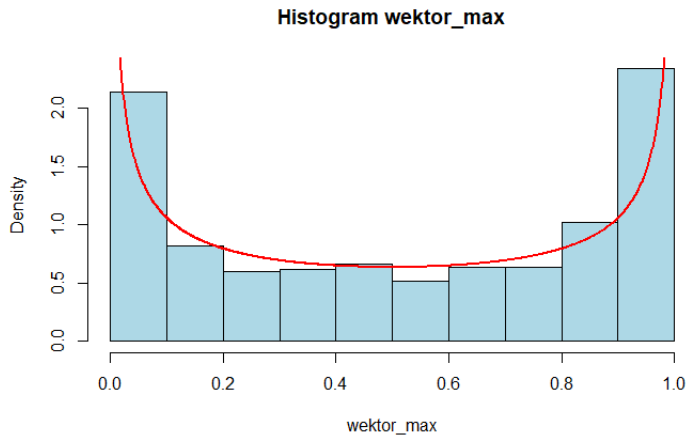
# Prawo arcus sinusa

```

6 sigma <- 0.2
7 p <- 500 # the number of samples
8 delta <- 0.001 # delta*n=T in years
9 n <- 999 # the number of steps
10 wektor_max <- c() #wektor maksimumów
11
12
13 for (k in 1:p) {
14   S <- 0
15   t <- 0
16   wektorS <- c()
17   for (j in 1:n) {
18     y <- rnorm(1) # Generate a random number from a standard normal distribution
19     #t <- t + delta
20     S <- S + sigma * y * sqrt(delta)
21     wektorS[j] <- S
22     #output <- rbind(output, data.frame(t = t, x = x))
23   }
24   wektor_max[k] <- which.max(wektorS)/1000
25 }
26
27 hist(wektor_max, col = "lightblue", main = "Histogram", prob=TRUE)
28
29 # Definiowanie funkcji gęstości rozkładu beta
30 x <- seq(from = 0.001, to = 0.999, by = 0.001)
31 y <- 1 / (pi * sqrt(x * (1 - x)))
32
33 # Rysowanie linii na tym samym wykresie
34 lines(x, y, col = "red", lwd = 2)

```

# Prawo arcus sinusa



Bez obliczania  $F^{-1}$ 

Metoda odwrotnej dystrybucyjności jest stosowana, nawet jeśli nie można analitycznie wyznaczyć odwzorowania  $F^{-1}$ . Wtedy obliczenie  $F^{-1}(u)$  jest równoważne znalezieniu miejsca zerowego równania  $F(x) - u = 0$ . Jeżeli  $f(x)$  jest gęstością naszego rozkładu, to korzystając z metody Newtona dostajemy:

$$x_{n+1} = x_n - \frac{F(x_n) - u}{f(x_n)},$$

gdzie, przy rozpoczęciu iteracji w punkcie  $x_0$ ,  $x_n$  zbiega do szukanego pierwiastka.

## Przykład - rozkład dyskretny

Rozważmy zmienną losową  $X$  o wartościach dyskretnych  $c_1 < c_2 < \dots < c_n$ . Niech  $p_i$  będzie prawdopodobieństwem osiągnięcia  $c_i$ . Następnie ustalmy  $q_0 = 0$  oraz

$$q_i = \sum_{j=1}^i p_j, \quad i = 1, \dots, n.$$

Zauważmy, że  $q_i = F(c_i)$ ,  $i = 1, \dots, n$ . Teraz stosujemy metodę odwrotnej dystrybucyjności:

- 1 losujemy liczbę  $U \sim U[0, 1]$ ;
- 2 szukamy  $K \in \{1, \dots, n\}$ , takie że  $q_{K-1} \leq U \leq q_K$ ;
- 3 przypisujemy  $X = c_K$ .



# Rozkład warunkowy

Rozważmy zmienną losową  $X$  i losowanie warunkowane  $a < X \leq b$ , gdzie  $a, b \in \mathbb{R}$  są, takie że  $F(a) < F(b)$ . Zdefiniujmy zmienną losową  $V$ :

$$V = F(a) + (F(b) - F(a))U.$$

Zauważmy, że  $V$  ma rozkład  $U[F(a), F(b)]$  i rozkład:

$$\begin{aligned} P(F^{-1}(V) \leq x) &= P(F(a) + (F(b) - F(a))U \leq F(x)) \\ &= P(U \leq [F(x) - F(a)]/[F(b) - F(a)]) \\ &= [F(x) - F(a)]/[F(b) - F(a)]. \end{aligned}$$

Dostaliśmy rozkład warunkowy dla  $a < X \leq b$ .

# Zadanie

## Zadanie

Napisz program, który, przy pomocy metody odwrotnej dystrybucyj, wygeneruje próbkę 20 liczb z rozkładu arcus sinusa.

Rozwiązanie:

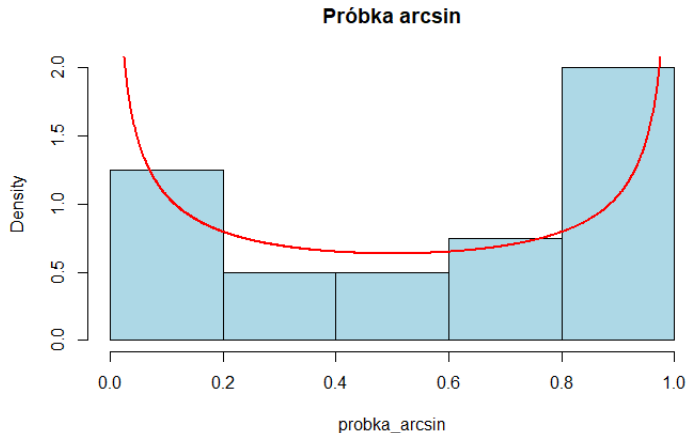
- 1 znaleźć funkcję  $F^{-1}(u) = \sin^2(u\frac{\pi}{2}) = \frac{1}{2} - \frac{1}{2} \cos(u\pi)$ ;
- 2 napisać kod.

```

14 #Metoda odwrotnej dystrybucyj dla rozkładu arcsin
15
16 probka_arcsin <- c()
17 probka_arcsin <- 0.5-0.5*cos(runif(20)*pi)
18
19 hist(probka_arcsin, col = "lightblue", main = "Próbka arcsin", prob=TRUE)
20 x <- seq(from = 0.001, to = 0.999, by = 0.001)
21 y <- 1 / (pi * sqrt(x * (1 - x))) #gęstość arcsin
22 lines(x, y, col = "red", lwd = 2)
23

```

## Zadanie



```
> print(probka_arcsin)
[1] 0.006881820 0.827185241 0.901494517 0.933918682 0.867600915 0.467945633 0.230592614 0.581440301 0.978017077
[10] 0.491967789 0.062035470 0.755816095 0.111089756 0.167381695 0.895387184 0.838456811 0.997979273 0.272097322
[19] 0.002545446 0.742030710
```

# Źródła

- 1 Paul Glasserman: "Monte Carlo Methods in Financial Engineering";
- 2 [https://en.wikipedia.org/wiki/Arcsine\\_distribution](https://en.wikipedia.org/wiki/Arcsine_distribution)
- 3 [https://en.wikipedia.org/wiki/Arcsine\\_laws\\_\(Wiener\\_process\)](https://en.wikipedia.org/wiki/Arcsine_laws_(Wiener_process))